3D Gaussian Splatting에서 GART까지

A Comprehensive Guide from Neural Radiance Fields to Gaussian Articulated Representations

컴퓨터 비전 & 3D 재구성

기초 이론부터 최신 연구까지

2026

본 교재는 NeRF, 3D Gaussian Splatting, 인체 모델링(SMPL/SMPL-X), 그리고 GART를 포함한 인체 3D 재구성 기술을 체계적으로 다룹니다.

Contents

서문 **4**

1 Neural Radiance Fields (NeRF) **5**
1.1 개요와 동기 5
1.1.1 왜 NeRF를 먼저 이해해야 하는가 5
1.2 장면 표현 (Scene Representation) 5
1.3 위치 인코딩 (Positional Encoding) 6
1.4 MLP 아키텍처 6
1.5 볼륨 렌더링 (Volume Rendering) 6
1.5.1 레이 매개변수화 7
1.5.2 연속 볼륨 렌더링 적분 7
1.5.3 이산 근사 (Numerical Quadrature) 7
1.6 계층적 샘플링 (Hierarchical Sampling) 7
1.7 학습 (Training) 8
1.7.1 손실 함수 8
1.7.2 학습 파이프라인 8
1.8 NeRF의 한계 8

2 3D Gaussian Splatting (3DGS) **9**
2.1 개요 9
2.2 3D 가우시안 프리미티브 9
2.3 공분산 행렬의 매개변수화 9
2.4 구면 조화 (Spherical Harmonics) 10
2.5 스플래팅: 3D → 2D 투영 10
2.5.1 투영 과정 10
2.6 알파 블렌딩 렌더링 11
2.7 타일 기반 미분 가능 래스터라이저 11
2.8 적응적 밀도 제어 (Adaptive Density Control) 11
2.8.1 복제 (Cloning) 12
2.8.2 분할 (Splitting) 12
2.8.3 가지치기 (Pruning) 12
2.9 학습 손실 함수 12
2.10 3DGS vs NeRF 비교 12

3 인체 파라메트릭 모델: SMPL과 SMPL-X **14**
3.1 개요 14
3.2 모델 사양 14
3.3 SMPL 파이프라인 15
3.3.1 Step 1: 체형 블렌드 셰이프 (Shape Blend Shapes) 15

3.3.2 Step 2: 자세 블렌드 셰이프 (Pose Blend Shapes) . . . 15
3.3.3 Step 3: 보정된 템플릿 . . . 15
3.3.4 Step 4: 관절 회귀 (Joint Regression) . . . 15
3.4 순방향 운동학 (Forward Kinematics) . . . 16
3.4.1 로컬 관절 변환 . . . 16
3.4.2 글로벌 관절 변환 . . . 16
3.5 선형 혼합 스키닝 (Linear Blend Skinning) . . . 16
3.6 SMPL-X 확장 . . . 17

4 동적 3D Gaussian Splatting 18
4.1 문제 정의 . . . 18
4.2 4D Gaussian Splatting (4DGS) . . . 18
4.2.1 HexPlane 시공간 인코더 . . . 18
4.2.2 가우시안 변형 디코더 . . . 18
4.2.3 학습 및 성능 . . . 19
4.3 Deformable 3D Gaussians . . . 19
4.3.1 Annealed Smoothing . . . 19
4.4 동적 접근법 비교 . . . 19

5 GART: Gaussian Articulated Representation Templates 20
5.1 개요와 동기 . . . 20
5.2 캐노니컬 공간 표현 . . . 20
5.3 가우시안의 순방향 스키닝 . . . 21
5.3.1 SMPL 템플릿 스키닝 . . . 21
5.3.2 학습 가능한 스키닝 가중치 보정 . . . 21
5.3.3 관절 변환 계산 . . . 21
5.4 잠재 뼈 (Latent Bones) . . . 21
5.4.1 잠재 뼈 변환 . . . 22
5.4.2 확장된 순방향 스키닝 . . . 22
5.5 자세 의존적 외형 . . . 22
5.6 미분 가능 렌더링 . . . 22
5.7 손실 함수 . . . 22
5.7.1 주 학습 손실 . . . 22
5.7.2 매끄러움 정규화 . . . 23
5.7.3 정규화 정규화 (Normalization Regularization) . . . 23
5.7.4 전체 정규화 손실 . . . 23
5.8 학습 전략 . . . 23

6 관련 인체 3DGS 방법들 24
6.1 공통 프레임워크 . . . 24
6.2 GauHuman . . . 24
6.2.1 핵심 기여 . . . 24
6.2.2 성능 . . . 25
6.3 Animatable Gaussians . . . 25
6.3.1 핵심 기여 . . . 25
6.4 ExAvatar . . . 25
6.4.1 핵심 기여 . . . 25
6.5 HumanGaussian . . . 26
6.5.1 핵심 기여 . . . 26
6.6 비교 요약 . . . 26

6.7 기술 발전의 계보 26

7 수학적 부록 **28**
7.1 쿼터니언과 회전 28
7.1.1 쿼터니언 기초 28
7.1.2 쿼터니언 → 회전행렬 28
7.1.3 축-각도 → 회전행렬 (로드리게스) 28
7.2 구면 조화 (Spherical Harmonics) 28
7.3 SSIM (Structural Similarity Index) 29
7.4 KL 발산 (두 가우시안 사이) 29
7.5 동차 좌표와 원근 투영 29
7.5.1 월드 → 카메라 변환 29
7.5.2 카메라 → 이미지 투영 29

참고 문헌 **30**

용어집 **31**

서문

본 교재는 3D Gaussian Splatting(3DGS)의 기반 기술인 Neural Radiance Fields(NeRF)부터 시작하여, 명시적(explicit) 3D 표현 방식인 3DGS, 인체 파라메트릭 모델(SMPL/SMPL-X), 동적 장면 표현, 그리고 최종적으로 관절 기반 인체 아바타 생성 기술인 GART(Gaussian Articulated Representation Templates)까지의 발전 과정을 체계적으로 설명합니다.

각 장은 이전 장의 개념을 기반으로 구성되어 있어, 순서대로 읽으면 자연스럽게 이해할 수 있도록 설계하였습니다. 수학적 표기법을 일관되게 사용하며, 핵심 개념은 별도의 박스로 강조합니다.

이 교재를 읽기 위한 사전 지식

- 선형대수: 행렬 연산, 고유값 분해, SVD
- 미적분: 편미분, 체인룰, 적분
- 확률/통계: 가우시안 분포, 공분산 행렬
- 딥러닝 기초: MLP, 역전파, 경사하강법
- 컴퓨터 그래픽스 기초: 카메라 모델, 동차좌표, 래스터화

Chapter 1

Neural Radiance Fields (NeRF)

1.1 개요와 동기

3D 장면을 여러 각도에서 촬영한 2D 이미지들로부터 새로운 시점(novel view)의 이미지를 합성하는 것은 컴퓨터 비전의 핵심 문제입니다. 2020년 Mildenhall 등이 제안한 **NeRF(Neural Radiance Fields)**는 이 문제에 혁신적인 접근을 제시했습니다.

Key Idea

NeRF는 3D 장면을 **연속적인 체적 함수(continuous volumetric function)**로 표현합니다. 신경망(MLP)이 공간의 임의 좌표와 시선 방향을 입력받아 해당 지점의 색상과 밀도를 출력하며, 이를 **볼륨 렌더링(volume rendering)**으로 통합하여 이미지를 생성합니다.

1.1.1 왜 NeRF를 먼저 이해해야 하는가

3DGS를 이해하기 위해 NeRF를 먼저 다루는 이유는 다음과 같습니다:

1. **볼륨 렌더링 수식**: 3DGS의 알파 블렌딩은 NeRF의 이산화된 볼륨 렌더링과 수학적으로 동치입니다.
2. **미분 가능 렌더링**: 두 방법 모두 "렌더 후 비교(render-and-compare)" 패러다임으로 학습합니다.
3. **한계 인식**: NeRF의 속도 문제가 3DGS라는 대안을 낳았습니다.

1.2 장면 표현 (Scene Representation)

NeRF는 장면을 5D 함수로 모델링합니다:

$$F_\Theta : (\mathbf{x}, \mathbf{d}) \longrightarrow (\mathbf{c}, \sigma) \tag{1.1}$$

여기서:

- $\mathbf{x} = (x, y, z) \in \mathbb{R}^3$: 3D 공간 좌표
- $\mathbf{d} = (\theta, \phi) \in \mathbb{S}^2$: 2D 시선 방향 (단위 구 위의 방향 벡터)
- $\mathbf{c} = (r, g, b) \in [0, 1]^3$: 해당 지점에서 방출되는 색상
- $\sigma \in \mathbb{R}_{\geq 0}$: 체적 밀도 (volume density)

Important

핵심 설계 원칙: **밀도 σ는 위치 $\mathbf{x}$에만 의존**하고, **색상 $\mathbf{c}$는 위치와 방향 모두에 의존**합니다. 밀도가 방향에 독립적이므로 다시점 기하학적 일관성(multi-view consistency)이 보장되며, 색상의 방향 의존성은 반사광(specular highlight) 같은 view-dependent 효과를 표현합니다.

1.3 위치 인코딩 (Positional Encoding)

MLP는 본질적으로 **저주파 함수에 편향(spectral bias)**되어 있습니다. 즉, 좌표를 직접 입력하면 날카로운 엣지나 세밀한 텍스처를 표현하지 못합니다. 이를 해결하기 위해 입력을 고차원 공간으로 매핑하는 **위치 인코딩** γ를 적용합니다:

$$\gamma(p) = \Big(\sin(2^0\pi p),\ \cos(2^0\pi p),\ \sin(2^1\pi p),\ \cos(2^1\pi p),\ \ldots,\ \sin(2^{L-1}\pi p),\ \cos(2^{L-1}\pi p)\Big) \tag{1.2}$$

스칼라 p 하나가 $2L$차원 벡터로 확장됩니다. 각 좌표에 독립적으로 적용:

- 3D 위치 (x, y, z): $L = 10 \Rightarrow 3 \times 2 \times 10 = 60$차원
- 시선 방향 (3D 단위벡터): $L = 4 \Rightarrow 3 \times 2 \times 4 = 24$차원

Remark 1.1. 위치 인코딩은 Transformer의 positional encoding과 동일한 아이디어입니다. 서로 다른 주파수의 사인/코사인 기저를 사용하여, 네트워크가 다양한 스케일의 패턴을 학습할 수 있게 합니다. 2^l 항은 l이 커질수록 고주파를 담당합니다.

1.4 MLP 아키텍처

NeRF의 신경망 구조는 다음과 같습니다:

1. **입력:** 60차원 위치 인코딩 벡터 $\gamma(\mathbf{x})$
2. **은닉층 1–5:** 256채널 fully connected + ReLU 활성화
3. **스킵 연결:** 5번째 층에서 원래 입력 $\gamma(\mathbf{x})$를 concatenation
4. **은닉층 6–8:** 256채널 fully connected + ReLU
5. **밀도 출력:** 선형 층 $\rightarrow \sigma$ (활성화 없음, 음수 가능하나 ReLU로 클리핑)
6. **특징 벡터:** 256차원 벡터 추출
7. **방향 입력:** 특징 벡터 + 24차원 $\gamma(\mathbf{d})$ concatenation
8. **색상 출력:** 128채널 + ReLU $\rightarrow$ 3채널 + Sigmoid $\rightarrow \mathbf{c} \in [0, 1]^3$

밀도가 방향과 무관하게 먼저 결정되고, 색상은 방향 정보를 추가로 받아 결정되는 구조입니다.

1.5 볼륨 렌더링 (Volume Rendering)

NeRF는 카메라 레이(ray)를 따라 색상과 밀도를 적분하여 픽셀 색상을 계산합니다.

1.5.1 레이 매개변수화

카메라 원점 $\mathbf{o}$에서 방향 $\mathbf{d}$로 발사되는 레이:

$$\mathbf{r}(t) = \mathbf{o} + t\,\mathbf{d}, \quad t \in [t_n, t_f] \tag{1.3}$$

여기서 t_n, t_f는 근평면(near plane)과 원평면(far plane) 거리입니다.

1.5.2 연속 볼륨 렌더링 적분

레이를 따른 렌더링된 색상:

$$\boxed{C(\mathbf{r}) = \int_{t_n}^{t_f} T(t)\,\sigma(\mathbf{r}(t))\,\mathbf{c}(\mathbf{r}(t), \mathbf{d})\,dt} \tag{1.4}$$

여기서 **누적 투과율(accumulated transmittance)**은:

$$T(t) = \exp\left(-\int_{t_n}^{t} \sigma(\mathbf{r}(s))\,ds\right) \tag{1.5}$$

$T(t)$는 레이가 t_n에서 t까지 어떤 입자에도 부딪히지 않고 도달할 확률이며, $T(t)\,\sigma(t)$는 t 지점에서 레이가 정지할 확률 밀도 함수(PDF)를 형성합니다.

Key Idea

볼륨 렌더링의 직관: 레이가 장면을 관통하면서, 각 지점의 "불투명도"만큼 해당 지점의 색상을 누적합니다. 앞쪽의 불투명한 물체가 뒤를 가리는 것이 자연스럽게 표현됩니다.

1.5.3 이산 근사 (Numerical Quadrature)

연속 적분을 계산하기 위해 레이를 따라 N개의 점 $t_1 < t_2 < \cdots < t_N$을 샘플링합니다. 구간 간격 $\delta_i = t_{i+1} - t_i$일 때:

$$\hat{C}(\mathbf{r}) = \sum_{i=1}^{N} T_i \cdot \alpha_i \cdot \mathbf{c}_i \tag{1.6}$$

각 항의 정의:

$$\alpha_i = 1 - \exp(-\sigma_i \cdot \delta_i) \qquad \text{(샘플별 불투명도)} \tag{1.7}$$

$$T_i = \prod_{j=1}^{i-1} (1 - \alpha_j) \qquad \text{(이산 투과율)} \tag{1.8}$$

$$w_i = T_i \cdot \alpha_i \qquad \text{(샘플 가중치, } \sum_i w_i \leq 1\text{)} \tag{1.9}$$

이는 전통적인 **알파 합성(alpha compositing)**의 front-to-back 공식과 정확히 동일합니다.

1.6 계층적 샘플링 (Hierarchical Sampling)

균일 샘플링은 빈 공간에서도 불필요한 연산을 수행합니다. NeRF는 두 개의 네트워크를 사용하여 이를 해결합니다:

1. **Coarse 네트워크:** $N_c = 64$개 점을 **층화 샘플링(stratified sampling)**으로 추출. 레이 구간을 N_c개 균등 bin으로 나누고 각 bin에서 균일하게 1개 추출:

$$t_i \sim \mathcal{U}\left[t_n + \frac{i-1}{N_c}(t_f - t_n),\ \ t_n + \frac{i}{N_c}(t_f - t_n)\right] \tag{1.10}$$

2. **Fine 네트워크:** Coarse 가중치 w_i로 구간별 상수(piecewise-constant) PDF를 구성하고, **역변환 샘플링(inverse transform sampling)**으로 $N_f = 128$개 추가 점을 추출. 이 점들은 표면 근처에 집중됩니다.

3. Fine 네트워크는 총 $N_c + N_f$개 점을 모두 평가합니다.

1.7 학습 (Training)

1.7.1 손실 함수

Coarse와 fine 렌더링 모두에 대한 MSE 합:

$$\mathcal{L} = \sum_{\mathbf{r}\in\mathcal{R}} \left[\|\hat{C}_c(\mathbf{r}) - C_{\text{gt}}(\mathbf{r})\|_2^2 + \|\hat{C}_f(\mathbf{r}) - C_{\text{gt}}(\mathbf{r})\|_2^2\right] \tag{1.11}$$

여기서 $\mathcal{R}$은 미니배치 내 레이 집합, C_{gt}는 실제 이미지 픽셀 색상입니다.

1.7.2 학습 파이프라인

Algorithm 1 NeRF Training (1 iteration)

```
학습 이미지에서 레이 배치 R 샘플링
for all r ∈ R do
    층화 샘플링으로 N_c 개 점 생성
    Coarse MLP로 각 점의 (c, σ) 예측
    eq. (1.6)으로 coarse 색상 Ĉ_c(r) 계산
    Coarse 가중치로 N_f 개 중요도 샘플 추가 생성
    Fine MLP로 총 N_c + N_f 개 점의 (c, σ) 예측
    Fine 색상 Ĉ_f(r) 계산
end for
L 계산 후 역전파
Adam 옵티마이저로 Θ 업데이트
```

1.8 NeRF의 한계

- **렌더링 속도:** 픽셀마다 레이를 쏘고 수백 개의 MLP 쿼리가 필요 ⇒ 프레임당 수십 초
- **학습 시간:** 장면 하나에 수 시간 소요
- **편집 불가:** 암묵적(implicit) 표현이라 특정 물체를 선택적으로 수정하기 어려움
- **빈 공간 낭비:** 물체가 없는 곳에서도 네트워크를 쿼리해야 함

이러한 한계를 극복하기 위해 다음 장에서 소개할 **3D Gaussian Splatting**이 등장합니다.

Chapter 2

3D Gaussian Splatting (3DGS)

2.1 개요

2023년 Kerbl 등이 SIGGRAPH에서 발표한 **3D Gaussian Splatting**은 NeRF의 암묵적 신경망 표현을 **명시적(explicit) 3D 가우시안 집합**으로 대체합니다.

Key Idea

3DGS의 핵심 아이디어: 장면을 수십만~수백만 개의 **비등방성 3D 가우시안(anisotropic 3D Gaussian)** 타원체로 표현하고, 이를 2D 이미지 평면에 **스플래팅(splatting)**하여 미분 가능하게 렌더링합니다. 이 방식은 NeRF와 동등하거나 더 높은 품질을 달성하면서도 **1080p에서 100+ FPS** 실시간 렌더링이 가능합니다.

2.2 3D 가우시안 프리미티브

장면의 i번째 가우시안은 다음 매개변수로 정의됩니다:

매개변수	기호	설명
위치 (평균)	$\boldsymbol{\mu}_i \in \mathbb{R}^3$	가우시안의 중심점
공분산 행렬	$\boldsymbol{\Sigma}_i \in \mathbb{R}^{3\times 3}$	모양과 방향
불투명도	$\alpha_i \in (0, 1]$	투명도 제어
색상 (SH)	$\mathbf{f}_i \in \mathbb{R}^C$	구면 조화 계수

위치 $\mathbf{x}$에서 i번째 가우시안의 공간적 영향:

$$\boxed{G_i(\mathbf{x}) = \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^\top \boldsymbol{\Sigma}_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i)\right)} \tag{2.1}$$

이는 다변량 정규분포의 확률밀도함수에서 정규화 상수를 제외한 형태입니다.

2.3 공분산 행렬의 매개변수화

공분산 행렬 $\boldsymbol{\Sigma}$를 직접 최적화하면 **양의 준정치(positive semi-definite)** 조건을 위반할 수 있습니다. 이를 해결하기 위해 다음과 같이 분해합니다:

$$\mathbf{\Sigma}_i = \mathbf{R}_i \, \mathbf{S}_i \, \mathbf{S}_i^\top \, \mathbf{R}_i^\top \tag{2.2}$$

여기서:

- $\mathbf{R}_i \in \mathrm{SO}(3)$: 회전 행렬, 단위 쿼터니언 $\mathbf{q}_i \in \mathbb{R}^4$ ($\|\mathbf{q}\| = 1$)로 저장 → 4개 파라미터
- $\mathbf{S}_i = \mathrm{diag}(s_x, s_y, s_z)$: 대각 스케일링 행렬 → 3개 파라미터

이 분해는 $\mathbf{\Sigma}$가 항상 양의 준정치임을 **구조적으로 보장**합니다. 물리적으로, $\mathbf{R}$은 타원체의 방향을, $\mathbf{S}$는 각 축의 크기를 결정합니다.

Remark 2.1. 가우시안 하나의 총 파라미터 수: 위치(3) + 쿼터니언(4) + 스케일(3) + 불투명도(1) + SH($3 \times 16 = 48$, degree 3) = **59개**.

2.4 구면 조화 (Spherical Harmonics)

NeRF가 MLP로 시점 의존적 색상을 모델링하는 반면, 3DGS는 **구면 조화(SH) 계수**를 사용합니다. SH는 구면 위의 함수를 표현하는 직교 기저 함수 집합입니다.

차수 (Degree)	기저 수	누적 기저 수	표현 가능한 효과
0	1	1	확산(diffuse) 색상
1	3	4	선형 방향 변화
2	5	9	이차 변화 (부드러운 반사)
3	7	16	고차 효과 (날카로운 반사)

3DGS는 보통 3차 SH를 사용하여 RGB 3채널에 대해 $16 \times 3 = 48$개의 SH 계수를 저장합니다. 시선 방향 $\mathbf{d}$가 주어지면:

$$\mathbf{c}_i(\mathbf{d}) = \mathrm{SH}(\mathbf{R}_i^\top \mathbf{d},\ \mathbf{f}_i) \tag{2.3}$$

2.5 스플래팅: 3D → 2D 투영

NeRF의 레이 마칭(ray marching)과 달리, 3DGS는 **스플래팅**—3D 가우시안을 2D 이미지 평면에 투영—을 사용합니다.

2.5.1 투영 과정

3D 가우시안의 평균은 표준 원근 투영(perspective projection)으로 2D로 변환되고, 3D 공분산은 **야코비안(Jacobian) $\mathbf{J}$**을 사용한 아핀 근사로 2D 공분산이 됩니다:

$$\boldsymbol{\mu}_{\mathrm{2D}} = \pi(\boldsymbol{\mu}_i;\ \mathbf{E}, \mathbf{K}) \tag{2.4}$$

$$\mathbf{\Sigma}_{\mathrm{2D}} = \mathbf{J} \, \mathbf{W} \, \mathbf{\Sigma}_i \, \mathbf{W}^\top \mathbf{J}^\top \tag{2.5}$$

여기서:

- $\mathbf{E}$: 외부 파라미터(extrinsic) 행렬 (월드 → 카메라 변환)
- $\mathbf{K}$: 내부 파라미터(intrinsic) 행렬
- $\mathbf{W}$: 뷰 변환 행렬의 회전 부분

- **J**: 원근 투영의 야코비안 (가우시안 중심에서 평가)
- $\mathbf{\Sigma}_{2D} \in \mathbb{R}^{2\times 2}$: 결과 2D 타원

Important

NeRF는 **이미지 공간**에서 작업합니다 (픽셀마다 레이를 쏨). 3DGS는 **프리미티브 공간**에서 작업합니다 (각 가우시안을 이미지에 투영). 이 차이가 속도의 핵심 원인입니다: 빈 공간에 대한 연산이 전혀 없습니다.

2.6 알파 블렌딩 렌더링

겹치는 투영된 가우시안들을 깊이 순서로 정렬한 후 front-to-back 알파 합성:

$$\boxed{C(\mathbf{u}) = \sum_{i=1}^{N} T_i \cdot \alpha_i \cdot \mathbf{c}_i, \qquad T_i = \prod_{j=1}^{i-1}(1-\alpha_j)} \tag{2.6}$$

여기서 유효 불투명도(effective opacity)는:

$$\alpha_i = \text{opacity}_i \cdot G_{2D}(\mathbf{u} \mid \boldsymbol{\mu}_{2D,i},\ \mathbf{\Sigma}_{2D,i}) \tag{2.7}$$

G_{2D}는 2D 가우시안을 픽셀 좌표 $\mathbf{u}$에서 평가한 값입니다. 이 수식은 **NeRF의 이산 볼륨 렌더링(eq. (1.6))과 수학적으로 동치**이지만, 레이 공간이 아닌 이미지 공간에서 작동합니다.

2.7 타일 기반 미분 가능 래스터라이저

실시간 성능은 맞춤형 CUDA 타일 기반 래스터라이저로 달성됩니다:

1. **절두체 컬링(Frustum Culling)**: 시야 밖 가우시안 제거
2. **2D 투영**: $\boldsymbol{\mu}_{2D}, \mathbf{\Sigma}_{2D}$ 계산
3. **타일 할당**: 화면을 16×16 픽셀 타일로 분할; 각 가우시안을 겹치는 모든 타일에 할당
4. **가우시안 복제**: 여러 타일에 걸친 가우시안은 타일마다 복제
5. **Radix 정렬**: (타일 ID, 깊이) 쌍을 정렬 → 타일 내 front-to-back 순서
6. **타일별 블렌딩**: GPU 스레드가 병렬로 알파 합성. 누적 불투명도가 임계값(예: 0.9999)을 초과하면 **early stopping**

전체 파이프라인이 미분 가능하여 모든 가우시안 파라미터에 대한 그래디언트를 계산할 수 있습니다.

2.8 적응적 밀도 제어 (Adaptive Density Control)

학습 중 100 iteration마다 가우시안 집합을 세 가지 연산으로 조정합니다:

2.8.1 복제 (Cloning)

- **조건**: 위치 그래디언트 크기가 임계값 τ_{pos} 초과 **AND** 가우시안이 "작음" (최대 스케일 축 < 임계값)
- **동작**: 동일 위치에 가우시안을 복제 → 희소 영역 채움
- **직관**: 작은 가우시안이 큰 그래디언트를 받는다 = 더 많은 가우시안이 필요한 곳

2.8.2 분할 (Splitting)

- **조건**: 위치 그래디언트 크기 > τ_{pos} **AND** 가우시안이 "큼"
- **동작**: 원래 가우시안을 제거하고 두 개의 작은 가우시안으로 대체. 새 스케일 $s' = s/\phi$ ($\phi \approx 1.6$), 새 위치는 원래 분포에서 샘플링
- **직관**: 하나의 큰 가우시안이 세밀한 디테일을 가리고 있음

2.8.3 가지치기 (Pruning)

- 불투명도가 임계값 ϵ_α(예: 0.005) 미만인 가우시안 제거
- 지나치게 큰 가우시안 (월드 또는 스크린 공간) 제거
- 주기적으로 전체 불투명도를 0 근처로 리셋하고 유용한 가우시안만 회복되게 함

2.9 학습 손실 함수

$$\mathcal{L} = (1 - \lambda)\,\mathcal{L}_1 + \lambda\,\mathcal{L}_{\text{D-SSIM}} \tag{2.8}$$

여기서:

- $\mathcal{L}_1 = \|I - \hat{I}\|_1$: L1 광도 손실
- $\mathcal{L}_{\text{D-SSIM}} = \frac{1-\text{SSIM}(I,\hat{I})}{2}$: 구조적 유사성 손실
- $\lambda = 0.2$: 가중치 하이퍼파라미터

Adam 옵티마이저를 사용하며, 각 파라미터 유형(위치, 쿼터니언, 스케일, 불투명도, SH) 별로 서로 다른 학습률을 적용합니다.

2.10 3DGS vs NeRF 비교

측면	NeRF	3DGS
표현 방식	암묵적 (MLP)	명시적 (가우시안 프리미티브)
렌더링	레이 마칭 (픽셀 기반)	스플래팅 (프리미티브 기반)
렌더링 속도	프레임당 수 초	100+ FPS (실시간)
학습 시간	수 시간	수 분 ~ 1시간
메모리	작음 (MLP 가중치)	큼 (수백만 가우시안)
편집 가능성	어려움	자연스러움 (이동/삭제 가능)
빈 공간	불필요한 샘플링	연산 없음

Summary

3DGS는 NeRF의 "렌더 후 비교" 학습 패러다임을 유지하면서, 장면 표현을 MLP에서 명시적 가우시안 집합으로 바꿔 실시간 렌더링을 달성했습니다. 핵심 요소는: (1) 쿼터니언+스케일 공분산 분해, (2) SH 기반 시점 의존 색상, (3) 타일 기반 미분 가능 래스터라이저, (4) 적응적 밀도 제어입니다.

Chapter 3

인체 파라메트릭 모델: SMPL과 SMPL-X

3.1 개요

인체를 3D로 표현하기 위해서는 **관절 구조(articulation)**, **체형 변화(body shape variation)**, **자세에 따른 변형(pose-dependent deformation)**을 모두 다룰 수 있는 모델이 필요합니다. **SMPL(Skinned Multi-Person Linear Model)**은 수천 건의 3D 인체 스캔 데이터로부터 학습된 파라메트릭 모델로, 저차원 파라미터로 전체 인체 메시를 생성합니다.

Key Idea

SMPL의 핵심: 소수의 **체형 파라미터** $\boldsymbol{\beta}$와 **자세 파라미터** $\boldsymbol{\theta}$만으로 인체의 다양한 형태와 동작을 표현합니다. 이 파라미터들은 **선형 혼합 스키닝(Linear Blend Skinning, LBS)**을 통해 3D 메시 꼭짓점 좌표로 변환됩니다.

3.2 모델 사양

	SMPL	**SMPL-X**
꼭짓점 수	6,890	10,475
삼각면 수	13,776	20,908
관절 수	24 (23 + 루트)	54 (21 몸통 + 30 손 + 3 얼굴)
체형 파라미터 $\boldsymbol{\beta}$	$\mathbb{R}^{10}$ (최대 300)	$\mathbb{R}^{10}$ (최대 300)
자세 파라미터 $\boldsymbol{\theta}$	$\mathbb{R}^{72}$ (축-각도)	$\mathbb{R}^{165}$
표정 파라미터 $\boldsymbol{\psi}$	–	$\mathbb{R}^{10}$ (최대 100)

Remark 3.1. SMPL-X의 "X"는 e**X**pressive를 의미합니다. SMPL(몸통) + MANO(손) + FLAME(얼굴)을 하나로 통합한 모델입니다.

3.3 SMPL 파이프라인

SMPL 모델의 전체 수식:

$$\boxed{M(\boldsymbol{\beta}, \boldsymbol{\theta}) = \mathrm{LBS}\Big(\bar{\mathbf{T}} + B_S(\boldsymbol{\beta}) + B_P(\boldsymbol{\theta}),\ \ J(\boldsymbol{\beta}),\ \ \boldsymbol{\theta},\ \ \mathbf{W}\Big)} \tag{3.1}$$

4단계로 진행됩니다.

3.3.1 Step 1: 체형 블렌드 셰이프 (Shape Blend Shapes)

기본 템플릿 메시 $\bar{\mathbf{T}} \in \mathbb{R}^{3N}$ 에 체형 변화를 더합니다:

$$B_S(\boldsymbol{\beta}) = \sum_{n=1}^{|\boldsymbol{\beta}|} \beta_n \cdot \mathbf{S}_n \tag{3.2}$$

$\mathbf{S}_n \in \mathbb{R}^{3N}$ 은 PCA로 학습된 직교 주성분입니다. 10개 성분만으로도 키, 체중, 체형 비율 등 대부분의 변이를 포착합니다.

Definition 3.1 (블렌드 셰이프). **블렌드 셰이프(blend shape)**란 기본 메시에 더해지는 꼭짓점 변위 벡터입니다. 여러 블렌드 셰이프의 가중합으로 다양한 형태를 표현합니다. 이는 PCA 기저 벡터와 계수의 곱에 해당합니다.

3.3.2 Step 2: 자세 블렌드 셰이프 (Pose Blend Shapes)

자세에 따른 보정 변형(근육 팽창, 피부 늘어남 등):

$$B_P(\boldsymbol{\theta}) = \sum_{n=1}^{9K} \big(R_n(\boldsymbol{\theta}) - R_n(\boldsymbol{\theta}^*)\big) \cdot \mathbf{P}_n \tag{3.3}$$

여기서:

- $R_n(\boldsymbol{\theta})$: 관절 회전행렬의 원소들 (펼친 형태)
- $R_n(\boldsymbol{\theta}^*)$: 기본 자세(rest pose)에서의 회전행렬 원소들 (항등행렬)
- $\mathbf{P}_n \in \mathbb{R}^{3N}$: 자세 블렌드 셰이프 기저
- 기본 자세에서의 뺄셈은 $\boldsymbol{\theta} = \boldsymbol{\theta}^*$ 일 때 보정이 0이 되도록 보장

3.3.3 Step 3: 보정된 템플릿

체형과 자세 보정이 적용된 템플릿:

$$T_P(\boldsymbol{\beta}, \boldsymbol{\theta}) = \bar{\mathbf{T}} + B_S(\boldsymbol{\beta}) + B_P(\boldsymbol{\theta}) \tag{3.4}$$

3.3.4 Step 4: 관절 회귀 (Joint Regression)

관절 위치는 보정된 꼭짓점으로부터 회귀합니다:

$$J(\boldsymbol{\beta}) = \mathbf{J}_{\text{regressor}} \cdot \big(\bar{\mathbf{T}} + B_S(\boldsymbol{\beta})\big) \tag{3.5}$$

$\mathbf{J}_{\text{regressor}} \in \mathbb{R}^{K \times N}$ 은 희소(sparse) 회귀 행렬로, 각 관절이 소수의 꼭짓점 위치의 가중합으로 결정됩니다.

3.4 순방향 운동학 (Forward Kinematics)

관절 변환은 **운동학적 트리(kinematic tree)** 구조를 따릅니다.

3.4.1 로컬 관절 변환

관절 k의 로컬 변환 ($\boldsymbol{\theta}_k$는 축-각도(axis-angle) 표현):

$$\mathbf{T}_k^{\text{local}} = \begin{bmatrix} \mathbf{R}(\boldsymbol{\theta}_k) & J_k \\ \mathbf{0}^\top & 1 \end{bmatrix} \tag{3.6}$$

$\mathbf{R}(\boldsymbol{\theta}_k)$는 **로드리게스 공식(Rodrigues' formula)**으로 축-각도에서 회전행렬로 변환:

$$\mathbf{R}(\boldsymbol{\theta}) = \mathbf{I} + \sin\|\boldsymbol{\theta}\| \cdot [\hat{\boldsymbol{\theta}}]_\times + (1 - \cos\|\boldsymbol{\theta}\|) \cdot [\hat{\boldsymbol{\theta}}]_\times^2 \tag{3.7}$$

여기서 $\hat{\boldsymbol{\theta}} = \boldsymbol{\theta}/\|\boldsymbol{\theta}\|$이고 $[\cdot]_\times$는 반대칭 행렬(skew-symmetric matrix)입니다.

3.4.2 글로벌 관절 변환

부모 관절 $p(k)$에서 재귀적으로:

$$\mathbf{T}_k^{\text{global}} = \mathbf{T}_{p(k)}^{\text{global}} \cdot \mathbf{T}_k^{\text{local}} \tag{3.8}$$

기본 자세의 관절 위치를 제거하여 최종 스키닝 변환:

$$\mathbf{G}_k(\boldsymbol{\theta}, J) = \mathbf{T}_k^{\text{global}} \cdot (\mathbf{T}_k^{\text{rest}})^{-1} \tag{3.9}$$

3.5 선형 혼합 스키닝 (Linear Blend Skinning)

각 꼭짓점은 뼈 변환의 가중합으로 변형됩니다:

$$\boxed{\mathbf{v}_i' = \sum_{k=1}^{K} w_{k,i} \cdot \mathbf{G}_k(\boldsymbol{\theta}, J(\boldsymbol{\beta})) \cdot \mathbf{v}_i} \tag{3.10}$$

여기서:

- $\mathbf{v}_i = T_P(\boldsymbol{\beta}, \boldsymbol{\theta})_i$: 캐노니컬 공간의 i번째 꼭짓점 (블렌드 셰이프 보정 포함)
- $w_{k,i} \geq 0$: 관절 k가 꼭짓점 i에 미치는 스키닝 가중치, $\sum_k w_{k,i} = 1$
- $\mathbf{G}_k$: 관절 k의 글로벌 스키닝 변환
- $\mathbf{W} \in \mathbb{R}^{K \times N}$: 블렌드 가중치 행렬 (데이터로부터 학습)

Important

LBS의 한계: 관절이 크게 구부러지면 "candy-wrapper" 아티팩트가 발생합니다 (팔꿈치를 180도 구부리면 부피가 사라지는 현상). 이를 SMPL에서는 **자세 블렌드 셰이프**로 보정합니다.

3.6 SMPL-X 확장

SMPL-X는 **표정 블렌드 셰이프**를 추가합니다:

$$T_P(\boldsymbol{\beta}, \boldsymbol{\theta}, \boldsymbol{\psi}) = \bar{\mathbf{T}} + B_S(\boldsymbol{\beta}) + B_P(\boldsymbol{\theta}) + B_E(\boldsymbol{\psi}) \tag{3.11}$$

$$B_E(\boldsymbol{\psi}) = \sum_{n=1}^{|\boldsymbol{\psi}|} \psi_n \cdot \mathbf{E}_n \tag{3.12}$$

$\mathbf{E}_n$은 FLAME 얼굴 모델로부터 학습된 표정 기저입니다. SMPL-X는 다음을 통합합니다:

- **SMPL**: 몸통 모델
- **MANO**: 손 모델 (손목 포함 각 손 15개 관절)
- **FLAME**: 얼굴 모델 (턱, 눈, 표정 공간)

Summary

SMPL/SMPL-X는 "체형 $\boldsymbol{\beta}$ + 자세 $\boldsymbol{\theta} \to$ 3D 메시"의 **미분 가능한 매핑**을 제공합니다. 핵심 구성요소: (1) PCA 기반 체형/자세 블렌드 셰이프, (2) 관절 회귀, (3) 순방향 운동학, (4) 선형 혼합 스키닝. 이 모델은 이후 장에서 3DGS와 결합되어 인체 아바타를 생성하는 핵심 사전 지식(prior)으로 사용됩니다.

Chapter 4

동적 3D Gaussian Splatting

4.1 문제 정의

정적 3DGS는 특정 시점의 장면만 표현합니다. **동적 장면**—시간에 따라 형태와 외형이 변하는 장면—을 표현하려면 시간 차원을 추가로 다뤄야 합니다.

가장 단순한 접근은 프레임마다 독립적인 가우시안 집합을 유지하는 것이지만, 이는 $O(T \times N)$의 저장 공간이 필요하고 시간적 일관성(temporal consistency)을 보장하지 못합니다.

Key Idea

핵심 아이디어: **캐노니컬(canonical)** 가우시안 집합 하나를 유지하고, 시간 t에 따른 **변형 필드(deformation field)**로 가우시안 파라미터를 변환합니다. 저장 복잡도는 $O(N + F)$ (F: 변형 필드 파라미터)로 줄어듭니다.

4.2 4D Gaussian Splatting (4DGS)

Wu 등 (CVPR 2024)이 제안한 4DGS는 시공간 구조를 효율적으로 인코딩합니다.

4.2.1 HexPlane 시공간 인코더

4D 시공간 볼륨 (x, y, z, t)를 6개의 2D 특징 평면으로 분해합니다:

- **공간 평면 3개**: (x, y), (x, z), (y, z)
- **시공간 평면 3개**: (x, t), (y, t), (z, t)

각 평면 $\mathcal{R}_l$은 학습 가능한 2D 그리드(예: 64×64)입니다. 쿼리 점 (x, y, z, t)에 대해 각 평면에서 **이중선형 보간(bilinear interpolation)**으로 특징을 추출:

$$\mathbf{f}_h = \text{Concat}\big(\mathcal{R}_{xy}(x, y),\ \mathcal{R}_{xz}(x, z),\ \mathcal{R}_{yz}(y, z),\ \mathcal{R}_{xt}(x, t),\ \mathcal{R}_{yt}(y, t),\ \mathcal{R}_{zt}(z, t)\big) \tag{4.1}$$

다중 해상도 인코딩을 사용하여 거친 움직임과 세밀한 움직임을 모두 포착합니다.

4.2.2 가우시안 변형 디코더

경량 MLP가 융합된 특징을 세 개의 변형 헤드로 처리:

$$\mathbf{f}_d = \phi_d(\mathbf{f}_h) \quad \text{(융합 MLP)} \tag{4.2}$$
$$\Delta\mathbf{x} = \phi_x(\mathbf{f}_d) \quad \text{(위치 변형)} \tag{4.3}$$
$$\Delta\mathbf{r} = \phi_r(\mathbf{f}_d) \quad \text{(회전 변형)} \tag{4.4}$$
$$\Delta\mathbf{s} = \phi_s(\mathbf{f}_d) \quad \text{(스케일 변형)} \tag{4.5}$$

시간 t에서의 변형된 가우시안:

$$\mathbf{x}'(t) = \mathbf{x} + \Delta\mathbf{x}(t), \quad \mathbf{r}'(t) = \mathbf{r} + \Delta\mathbf{r}(t), \quad \mathbf{s}'(t) = \mathbf{s} + \Delta\mathbf{s}(t) \tag{4.6}$$

4.2.3 학습 및 성능

손실: $(1-\lambda)\mathcal{L}_1 + \lambda\mathcal{L}_{\text{D-SSIM}}$ + 시간 매끄러움 정규화.
성능: RTX 3090에서 800×800에서 82 FPS.

4.3 Deformable 3D Gaussians

Yang 등 (CVPR 2024)은 HexPlane 대신 **순수 MLP 기반 변형 필드**를 사용합니다:

$$F_\theta : \big(\gamma(\mathbf{x}),\ \gamma(t)\big) \longrightarrow (\Delta\mathbf{x},\ \Delta\mathbf{r},\ \Delta\mathbf{s}) \tag{4.7}$$

γ는 위치/시간 인코딩입니다.

4.3.1 Annealed Smoothing

실제 데이터의 부정확한 카메라 포즈에 대응하기 위한 기법:

- 초기 학습: 강한 시간적 매끄러움(temporal smoothness) 정규화 적용
- 학습 진행에 따라 점진적으로 완화
- 거친 움직임 → 세밀한 움직임 순서로 학습

4.4 동적 접근법 비교

방법	시간 인코딩	변형 구조	FPS
4DGS	HexPlane (6 평면)	다중 헤드 MLP	82
Deformable 3DGS	위치 인코딩	MLP	∼60
프레임별 독립 3DGS	없음 (독립)	없음	빠름

Summary

동적 3DGS는 "캐노니컬 가우시안 + 시간 의존 변형"이라는 공통 패러다임을 따릅니다. 이 패러다임은 다음 장에서 인체 모델(SMPL)과 결합될 때, 변형 필드를 **관절 기반 스키닝**으로 대체하는 방향으로 발전합니다.

Chapter 5

GART: Gaussian Articulated Representation Templates

5.1 개요와 동기

앞선 장에서 우리는 세 가지 핵심 구성요소를 배웠습니다:

1. **3DGS**: 명시적 가우시안으로 장면을 실시간 렌더링
2. **SMPL**: 자세/체형 파라미터로 인체 메시를 생성
3. **동적 3DGS**: 시간에 따른 가우시안 변형

GART(Lei et al., CVPR 2024)는 이들을 결합하여, 단안(monocular) 영상으로부터 **애니메이션 가능한 인체 아바타**를 생성합니다.

Key Idea

GART의 핵심: 3D 가우시안을 **캐노니컬 공간(기본 자세)**에 정의하고, SMPL의 **순방향 스키닝(forward skinning)**으로 관찰 자세로 변환합니다. 추가로 **잠재 뼈(latent bones)**라는 가상 관절을 도입하여 옷이나 머리카락 같은 비강체 변형도 표현합니다.

5.2 캐노니컬 공간 표현

캐노니컬 공간의 각 가우시안 i:

$$\boldsymbol{\mu}^{(i)} \in \mathbb{R}^3 \quad \text{(위치)} \tag{5.1}$$

$$\mathbf{R}^{(i)} \in \mathrm{SO}(3) \quad \text{(회전)} \tag{5.2}$$

$$\mathbf{s}^{(i)} \in \mathbb{R}^3_+ \quad \text{(비등방 스케일)} \tag{5.3}$$

$$\eta^{(i)} \in (0, 1] \quad \text{(불투명도)} \tag{5.4}$$

$$\mathbf{f}^{(i)} \in \mathbb{R}^C \quad \text{(SH 색상 계수)} \tag{5.5}$$

캐노니컬 공간에서의 밀도:

$$\sigma^{(i)}(\mathbf{x}_c) = \eta^{(i)} \cdot \exp\left(-\frac{1}{2}(\mathbf{x}_c - \boldsymbol{\mu}^{(i)})^\top (\boldsymbol{\Sigma}^{(i)})^{-1} (\mathbf{x}_c - \boldsymbol{\mu}^{(i)})\right) \tag{5.6}$$

여기서 $\boldsymbol{\Sigma}^{(i)} = \mathbf{R}^{(i)} \cdot \mathrm{diag}((\mathbf{s}^{(i)})^2) \cdot (\mathbf{R}^{(i)})^\top$ 입니다.

5.3 가우시안의 순방향 스키닝

GART는 캐노니컬 → 관찰 공간으로의 **순방향 스키닝(forward skinning)**을 사용합니다. 이는 명시적 가우시안 표현에 자연스럽습니다.

순방향 vs 역방향 스키닝

- **역방향 스키닝(inverse skinning)**: 관찰 공간 점 → 캐노니컬 공간. NeRF 기반 방법에서 주로 사용 (레이 위의 점을 캐노니컬 공간으로 매핑하여 MLP 쿼리).
- **순방향 스키닝(forward skinning)**: 캐노니컬 공간 점 → 관찰 공간. 명시적 표현(메시, 가우시안)에서 자연스러움 (캐노니컬 프리미티브를 직접 변환).

5.3.1 SMPL 템플릿 스키닝

표준 스키닝:

$$\mathbf{x} = \left(\sum_{k=1}^{n_b} W_k(\mathbf{x}_c) \cdot \mathbf{B}_k \right) \cdot \mathbf{x}_c \tag{5.7}$$

W_k는 스키닝 가중치, $\mathbf{B}_k$는 뼈 변환 행렬입니다.

5.3.2 학습 가능한 스키닝 가중치 보정

SMPL의 고정된 스키닝 가중치만으로는 가우시안의 자유로운 변형을 표현하기 어렵습니다. GART는 **가우시안별 학습 가능 보정(per-Gaussian learnable correction)**을 추가합니다:

$$\hat{W}(\boldsymbol{\mu}^{(i)}) = W(\boldsymbol{\mu}^{(i)}) + \Delta\mathbf{w}^{(i)} \tag{5.8}$$

$\Delta\mathbf{w}^{(i)} \in \mathbb{R}^{n_b}$는 i번째 가우시안의 학습 가능한 스키닝 가중치 보정입니다. 이를 통해 가우시안이 SMPL 메시에 엄격히 묶이지 않고 옷 등의 변형을 표현할 수 있습니다.

5.3.3 관절 변환 계산

i번째 가우시안의 관절 변환:

$$\mathbf{A}^{(i)} = \sum_{k=1}^{n_b} \hat{W}_k(\boldsymbol{\mu}^{(i)}) \cdot \mathbf{B}_k \tag{5.9}$$

$\mathbf{A}^{(i)}$를 회전 부분 $\mathbf{A}_{\text{rot}}^{(i)}$과 이동 부분 $\mathbf{A}_t^{(i)}$로 분리하면, 변형된 가우시안 파라미터:

$$\boldsymbol{\mu}_{\text{art}}^{(i)} = \mathbf{A}_{\text{rot}}^{(i)} \cdot \boldsymbol{\mu}^{(i)} + \mathbf{A}_t^{(i)} \tag{5.10}$$

$$\mathbf{R}_{\text{art}}^{(i)} = \mathbf{A}_{\text{rot}}^{(i)} \cdot \mathbf{R}^{(i)} \tag{5.11}$$

Remark 5.1. 스케일 $\mathbf{s}^{(i)}$와 불투명도 $\eta^{(i)}$는 변환하지 않습니다. 이들은 가우시안의 **로컬 기하학**을 기술하며, 자세 변환은 가우시안의 위치와 방향만 변경해야 합니다.

5.4 잠재 뼈 (Latent Bones)

실제 변형(느슨한 옷, 머리카락, 연조직 등)은 골격 LBS만으로 표현할 수 없습니다. GART는 **잠재 뼈(latent bones)**—템플릿 스켈레톤에 없는 가상의 추가 뼈—를 도입합니다.

5.4.1 잠재 뼈 변환

$$[\tilde{\mathbf{B}}_1, \ldots, \tilde{\mathbf{B}}_{n_l}] = \tilde{B}(\boldsymbol{\theta}) \tag{5.12}$$

잠재 뼈 변환은 자세 $\boldsymbol{\theta}$의 함수로, MLP 또는 프레임별 최적화 가능한 룩업 테이블로 매개변수화됩니다.

5.4.2 확장된 순방향 스키닝

잠재 뼈를 포함한 전체 관절 변환:

$$\boxed{\mathbf{A}^{(i)} = \underbrace{\sum_{k=1}^{n_b} \hat{W}_k(\boldsymbol{\mu}^{(i)}) \cdot \mathbf{B}_k}_{\text{SMPL 스켈레톤 변환}} + \underbrace{\sum_{q=1}^{n_l} \tilde{W}_q(\boldsymbol{\mu}^{(i)}) \cdot \tilde{\mathbf{B}}_q}_{\text{잠재 뼈 변환}}} \tag{5.13}$$

$\tilde{W}_q$는 잠재 뼈의 학습 가능한 스키닝 가중치입니다.

Key Idea

잠재 뼈의 직관: SMPL의 24개 뼈로는 옷의 펄럭임이나 머리카락의 흔들림을 표현할 수 없습니다. 잠재 뼈는 이러한 비강체 변형을 자세 의존적 "가상 관절"로 모델링합니다. 자세가 바뀌면 잠재 뼈도 반응하여 일관된 변형을 생성합니다.

5.5 자세 의존적 외형

자세 $\boldsymbol{\theta}$에서의 완전한 관절 표현:

$$\mathcal{G}_{\text{art}}(\boldsymbol{\theta}) = \{(\boldsymbol{\mu}_{\text{art}}^{(i)},\ \mathbf{R}_{\text{art}}^{(i)},\ \mathbf{s}^{(i)},\ \eta^{(i)},\ \mathbf{f}^{(i)})\}_{i=1}^{N} \tag{5.14}$$

SH 계수 $\mathbf{f}^{(i)}$로 시점 의존 색상을 제공하며, $\mathbf{R}_{\text{art}}^{(i)}$에 의해 적절히 회전됩니다.

5.6 미분 가능 렌더링

각 관절 변환된 가우시안의 2D 투영:

$$\boldsymbol{\mu}_{\text{2D}} = \pi(\boldsymbol{\mu}_{\text{art}};\ \mathbf{E}, \mathbf{K}) \tag{5.15}$$

$$\boldsymbol{\Sigma}_{\text{2D}} = \mathbf{J} \cdot \mathbf{E} \cdot \boldsymbol{\Sigma}_{\text{art}} \cdot \mathbf{E}^\top \cdot \mathbf{J}^\top \tag{5.16}$$

볼륨 렌더링 (스플래팅):

$$I(\mathbf{u}, \mathbf{d}) = \sum_{i=1}^{N} \alpha^{(i)} \cdot \text{SH}(\mathbf{R}^\top \mathbf{d},\ \mathbf{f}^{(i)}) \cdot \prod_{j=1}^{i-1} (1 - \alpha^{(j)}) \tag{5.17}$$

5.7 손실 함수

5.7.1 주 학습 손실

$$\mathcal{L} = \mathcal{L}_1(\hat{I}, I^*) + \lambda_{\text{SSIM}} \cdot \mathcal{L}_{\text{SSIM}}(\hat{I}, I^*) + \mathcal{L}_{\text{reg}} \tag{5.18}$$

5.7.2 매끄러움 정규화

인접 가우시안 간의 속성 일관성:

$$\mathcal{L}_{\text{STD}}^{(i)} = \sum_{\text{attr}\in\{\mathbf{R},\mathbf{s},\eta,\mathbf{f},\hat{W},\tilde{W}\}} \lambda_{\text{attr}} \cdot \text{STD}_{j\in\text{KNN}(\boldsymbol{\mu}^{(i)})}(\text{attr}^{(j)}) \tag{5.19}$$

K-최근접 이웃(KNN)의 속성 표준편차를 페널티합니다. 이는 인접 가우시안이 유사한 속성을 갖도록 유도하여 공간적 매끄러움을 보장합니다.

5.7.3 정규화 정규화 (Normalization Regularization)

$$\mathcal{L}_{\text{norm}}^{(i)} = \lambda_{\hat{W}}\|\Delta\mathbf{w}^{(i)}\|_2 + \lambda_{\tilde{W}}\|\tilde{W}(\boldsymbol{\mu}^{(i)})\|_2 + \lambda_s\|\mathbf{s}^{(i)}\|_\infty \tag{5.20}$$

각 항의 역할:

- $\|\Delta\mathbf{w}^{(i)}\|_2$: 스키닝 가중치 보정을 작게 유지 (SMPL 템플릿에 가깝게)
- $\|\tilde{W}(\boldsymbol{\mu}^{(i)})\|_2$: 잠재 뼈 가중치를 최소화 (필요할 때만 활성화)
- $\|\mathbf{s}^{(i)}\|_\infty$: 스케일을 제한 (지나치게 큰 가우시안 방지)

5.7.4 전체 정규화 손실

$$\mathcal{L}_{\text{reg}} = \frac{1}{N}\sum_{i=1}^{N}\left[\mathcal{L}_{\text{STD}}^{(i)} + \mathcal{L}_{\text{norm}}^{(i)}\right] \tag{5.21}$$

5.8 학습 전략

1. **초기화**: SMPL 메시 표면 위의 꼭짓점(6,890개)에 가우시안 배치
2. **동시 최적화**: 가우시안 파라미터 $\mathcal{G}$, 스키닝 보정 $\hat{W}$, 잠재 뼈 변환 $\tilde{B}$, 잠재 뼈 가중치 $\tilde{W}$ 동시 최적화
3. **선택적 자세 정제**: 추정된 SMPL 자세 $\boldsymbol{\theta}$를 함께 최적화 가능
4. **적응적 밀도 제어**: 3DGS 스타일의 분할/복제/가지치기 적용
5. **복셀 증류 스키닝**: 선택적으로 스키닝 가중치를 공간 복셀 그리드에 증류하여 더 매끄러운 변형 달성

Summary

GART 학습 파이프라인 요약:

1. SMPL 메시 위에 가우시안 초기화
2. 각 학습 프레임에 대해: 캐노니컬 가우시안 $\xrightarrow{\text{순방향 스키닝 (확장)}}$ 관찰 자세 가우시안 $\xrightarrow{\text{타일 래스터라이저}}$ 렌더링 이미지
3. 렌더링 이미지와 실제 이미지 비교하여 손실 계산
4. 역전파로 모든 파라미터 업데이트

학습 시간: 표준 하드웨어에서 30초 ∼ 2.5분. 렌더링: 150+ FPS.

Chapter 6

관련 인체 3DGS 방법들

6.1 공통 프레임워크

대부분의 방법이 공유하는 **캐노니컬-포즈드(canonical-to-posed)** 패러다임:

1. 캐노니컬 (기본 자세) 공간에서 3D 가우시안 정의 (보통 SMPL/SMPL-X로 초기화)
2. 변형 모델 (주로 LBS 기반)로 목표 자세로 변환
3. 미분 가능 래스터화로 렌더링
4. 광도 손실로 실제 이미지와 비교하여 최적화

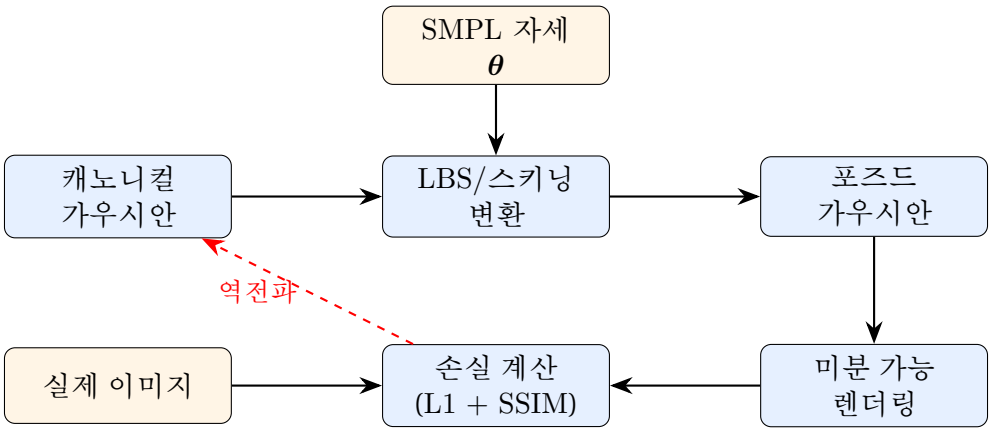

Figure 6.1: 인체 3DGS 방법의 공통 학습 파이프라인

6.2 GauHuman

Hu 등 (CVPR 2024)은 단안 영상에서 관절 아바타를 생성합니다.

6.2.1 핵심 기여

1. **SMPL 초기화**: 6,890개 SMPL 꼭짓점에 가우시안 초기화
2. **LBS 가중치 정제**: MLP로 SMPL 스키닝 가중치에 오프셋 예측:

$$w_k = \mathrm{softmax}\big(\log(w_k^{\mathrm{SMPL}} + \epsilon) + \mathrm{MLP}(\gamma(\mathbf{p}^c))[k]\big) \tag{6.1}$$

3. **자세 정제**: 학습 가능한 상대 쿼터니언 보정:

$$\boldsymbol{\theta} = \boldsymbol{\theta}^{\text{SMPL}} \otimes \text{MLP}(\boldsymbol{\theta}) \tag{6.2}$$

4. **KL-발산 기반 가우시안 제어**: 그래디언트 임계값 대신 가우시안 간 KL 발산을 사용:

$$\text{KL}(G_0 \| G_1) = \frac{1}{2}\left(\text{tr}(\boldsymbol{\Sigma}_1^{-1}\boldsymbol{\Sigma}_0) + \ln\frac{|\boldsymbol{\Sigma}_1|}{|\boldsymbol{\Sigma}_0|} + (\mathbf{p}_1 - \mathbf{p}_0)^\top \boldsymbol{\Sigma}_1^{-1}(\mathbf{p}_1 - \mathbf{p}_0) - 3\right) \tag{6.3}$$

   복잡도를 $O(U^2)$에서 $O(U)$로 줄이며, KL < 0.1인 중복 가우시안을 **병합(merge)** 가능

6.2.2 성능

학습: 1–2분, 렌더링: 189 FPS, 가우시안 수: ∼13K.

6.3 Animatable Gaussians

Li 등 (CVPR 2024)은 다시점 영상에서 고품질 인체 아바타를 생성합니다.

6.3.1 핵심 기여

1. **UV 가우시안 맵**: 템플릿 메시를 앞/뒤 두 개의 UV 맵으로 매개변수화. 각 UV 텍셀이 하나의 가우시안을 표현
2. **StyleUNet**: 자세 조건부 CNN이 UV 맵에서 가우시안 속성 (위치 오프셋, 회전, 스케일, 불투명도, 색상) 예측
3. **입력**: SMPL-X 꼭짓점 위치를 인코딩한 UV-포지션 맵 + 자세 파라미터
4. **자세 투영**: PCA를 적용하여 학습되지 않은 새로운 자세도 일반화

Important

Animatable Gaussians는 3D 가우시안을 2D UV 공간에서 정의합니다. 이 2D 매개변수화 덕분에 강력한 2D CNN 아키텍처를 활용할 수 있어, 느슨한 옷의 동적 변형을 잘 표현합니다.

6.4 ExAvatar

Moon 등 (ECCV 2024)은 짧은 단안 영상에서 **표현력 있는 전신 아바타**(얼굴 + 손 + 몸통)를 생성합니다.

6.4.1 핵심 기여

1. **메시-가우시안 하이브리드**: 각 가우시안을 SMPL-X 토폴로지를 따르는 메시의 꼭짓점으로 취급. 167K 꼭짓점, 335K 면 (SMPL-X 메시를 세분화)
2. **트라이플레인 특징 추출**: 학습 가능한 트라이플레인 $\mathcal{T} \in \mathbb{R}^{3\times32\times128\times128}$에서 꼭짓점별 특징을 직교 투영 + 이중선형 보간으로 추출. 얼굴 전용 트라이플레인도 별도 사용
3. **가우시안 속성 회귀**: 두 MLP가 트라이플레인 특징을 처리:

- 정체성 의존: 3D 오프셋 ΔV_{tri}, 스케일, RGB
- 자세 의존: 꼭짓점 오프셋 ΔV_{pose}, 스케일/RGB 오프셋

모든 가우시안은 **등방성(isotropic)** (회전 = 항등, 불투명도 = 1) → 일반화 향상

4. **표정 구동 변형**: SMPL-X 표정 오프셋 직접 사용:

$$\bar{V}_{\text{pose}} = \bar{V} + \Delta V_{\text{tri}} + \Delta V_{\text{pose}} + \Delta V_{\text{expr}} \tag{6.4}$$

5. **연결성 기반 정규화**: 라플라시안 정규화로 메시 연결성을 활용한 매끄러움 보장

6.5 HumanGaussian

Liu 등 (CVPR 2024 Highlight)은 텍스트로부터 3D 인체를 **생성**합니다 (재구성이 아님).

6.5.1 핵심 기여

1. **구조 인식 SDS(Score Distillation Sampling)**: RGB 이미지와 깊이 맵을 동시에 디노이징하는 이중 분기 모델
2. SMPL-X 표면에 밀집된 가우시안 초기화
3. 생성임에도 SMPL-X 자세 시퀀스로 제로샷 애니메이션 가능

6.6 비교 요약

방법	입력	SMPL	핵심 혁신	학습	FPS
GART	단안 영상	SMPL	잠재 뼈 + 가중치 보정	0.5–2.5분	150+
GauHuman	단안 영상	SMPL	KL 기반 밀도 제어	1–2분	189
Anim. Gauss.	다시점	SMPL-X	StyleUNet UV 맵	∼2일	10
ExAvatar	단안 영상	SMPL-X	메시-가우시안 하이브리드	1.5–5시간	실시간
HumanGaussian	텍스트	SMPL-X	구조 인식 SDS	수 시간	–

6.7 기술 발전의 계보

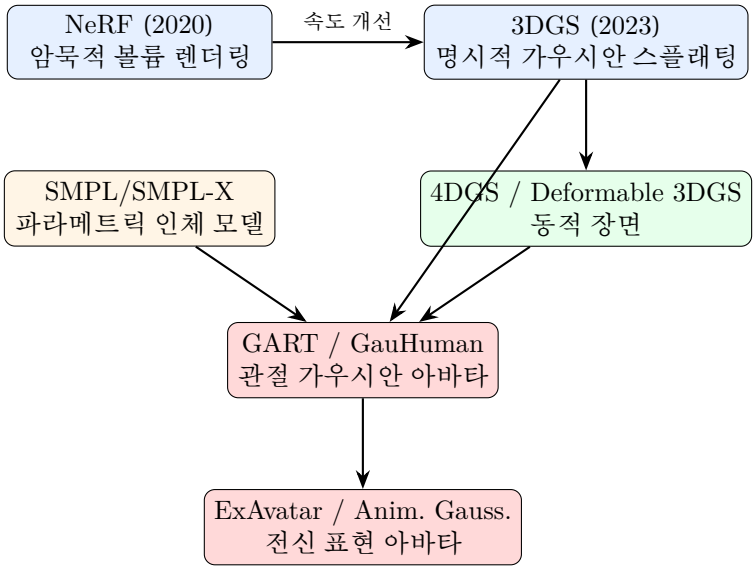

Figure 6.2: NeRF에서 인체 가우시안 아바타까지의 기술 계보

Chapter 7

수학적 부록

7.1 쿼터니언과 회전

7.1.1 쿼터니언 기초

단위 쿼터니언 $\mathbf{q} = (q_w, q_x, q_y, q_z)$, $\|\mathbf{q}\| = 1$은 3D 회전을 표현합니다.

회전축 $\hat{\mathbf{n}}$과 회전각 θ에 대해:

$$\mathbf{q} = \left(\cos\frac{\theta}{2},\ \ \hat{\mathbf{n}}\sin\frac{\theta}{2}\right) \tag{7.1}$$

7.1.2 쿼터니언 → 회전행렬

$$\mathbf{R}(\mathbf{q}) = \begin{bmatrix} 1-2(q_y^2+q_z^2) & 2(q_xq_y - q_wq_z) & 2(q_xq_z + q_wq_y) \\ 2(q_xq_y + q_wq_z) & 1-2(q_x^2+q_z^2) & 2(q_yq_z - q_wq_x) \\ 2(q_xq_z - q_wq_y) & 2(q_yq_z + q_wq_x) & 1-2(q_x^2+q_y^2) \end{bmatrix} \tag{7.2}$$

7.1.3 축-각도 → 회전행렬 (로드리게스)

축-각도 벡터 $\boldsymbol{\theta} \in \mathbb{R}^3$에서 $\theta = \|\boldsymbol{\theta}\|$, $\hat{\boldsymbol{\theta}} = \boldsymbol{\theta}/\theta$:

$$\mathbf{R}(\boldsymbol{\theta}) = \cos\theta\,\mathbf{I} + (1-\cos\theta)\,\hat{\boldsymbol{\theta}}\hat{\boldsymbol{\theta}}^\top + \sin\theta\,[\hat{\boldsymbol{\theta}}]_\times \tag{7.3}$$

반대칭 행렬:

$$[\hat{\boldsymbol{\theta}}]_\times = \begin{bmatrix} 0 & -\hat{\theta}_z & \hat{\theta}_y \\ \hat{\theta}_z & 0 & -\hat{\theta}_x \\ -\hat{\theta}_y & \hat{\theta}_x & 0 \end{bmatrix} \tag{7.4}$$

7.2 구면 조화 (Spherical Harmonics)

실수 SH 기저 함수 $Y_l^m(\theta, \phi)$ (차수 l, 차수 m, $-l \le m \le l$):

- $l = 0$: $Y_0^0 = \frac{1}{2\sqrt{\pi}}$ (상수)
- $l = 1$: 3개 기저 (선형 방향 의존성)

$$Y_1^{-1} = \sqrt{\tfrac{3}{4\pi}}\,y, \quad Y_1^0 = \sqrt{\tfrac{3}{4\pi}}\,z, \quad Y_1^1 = \sqrt{\tfrac{3}{4\pi}}\,x \tag{7.5}$$

여기서 (x, y, z)는 단위 방향 벡터의 좌표

- $l = 2$: 5개 기저 (이차 의존성)
- $l = 3$: 7개 기저 (삼차 의존성)

방향 $\mathbf{d}$에서의 색상 (R/G/B 각 채널):

$$c(\mathbf{d}) = \sum_{l=0}^{l_{\max}} \sum_{m=-l}^{l} f_l^m \cdot Y_l^m(\mathbf{d}) \tag{7.6}$$

3DGS에서 $l_{\max} = 3$이면 총 $(0+1)+(1+2)+(2+3)+(3+4) = 1+3+5+7 = 16$개 기저.

7.3 SSIM (Structural Similarity Index)

두 이미지 패치 x, y에 대해:

$$\mathrm{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \tag{7.7}$$

여기서 μ는 평균, σ^2은 분산, σ_{xy}는 공분산, C_1, C_2는 안정화 상수입니다.
D-SSIM 손실: $\mathcal{L}_{\text{D-SSIM}} = \frac{1-\mathrm{SSIM}}{2}$

7.4 KL 발산 (두 가우시안 사이)

두 다변량 가우시안 $\mathcal{N}_0(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0), \mathcal{N}_1(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1)$ (d차원):

$$\mathrm{KL}(\mathcal{N}_0 \| \mathcal{N}_1) = \frac{1}{2}\left[\mathrm{tr}(\boldsymbol{\Sigma}_1^{-1}\boldsymbol{\Sigma}_0) + (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)^\top \boldsymbol{\Sigma}_1^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0) - d + \ln\frac{|\boldsymbol{\Sigma}_1|}{|\boldsymbol{\Sigma}_0|}\right] \tag{7.8}$$

GauHuman에서는 이를 가우시안 분할/병합 기준으로 사용합니다 ($d = 3$).

7.5 동차 좌표와 원근 투영

7.5.1 월드 → 카메라 변환

외부 파라미터 $[\mathbf{R}_{\text{cam}} | \mathbf{t}_{\text{cam}}]$:

$$\mathbf{p}_{\text{cam}} = \mathbf{R}_{\text{cam}}\mathbf{p}_{\text{world}} + \mathbf{t}_{\text{cam}} \tag{7.9}$$

7.5.2 카메라 → 이미지 투영

내부 파라미터 $\mathbf{K}$:

$$\mathbf{K} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \tag{7.10}$$

원근 투영 (z 나누기 포함):

$$\begin{bmatrix} u \\ v \end{bmatrix} = \begin{bmatrix} f_x \cdot x/z + c_x \\ f_y \cdot y/z + c_y \end{bmatrix} \tag{7.11}$$

이 투영의 야코비안 $\mathbf{J}$가 eq. (2.5)에서 3D 공분산을 2D로 근사 변환할 때 사용됩니다.

참고 문헌

[1] Mildenhall, B. et al. "NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis." *ECCV*, 2020.

[2] Kerbl, B. et al. "3D Gaussian Splatting for Real-Time Radiance Field Rendering." *ACM Transactions on Graphics* (*SIGGRAPH*), 2023.

[3] Loper, M. et al. "SMPL: A Skinned Multi-Person Linear Model." *ACM Transactions on Graphics* (*SIGGRAPH Asia*), 2015.

[4] Pavlakos, G. et al. "Expressive Body Capture: 3D Hands, Face, and Body from a Single Image." (SMPL-X) *CVPR*, 2019.

[5] Wu, G. et al. "4D Gaussian Splatting for Real-Time Dynamic Scene Rendering." *CVPR*, 2024.

[6] Yang, Z. et al. "Deformable 3D Gaussians for High-Fidelity Monocular Dynamic Scene Reconstruction." *CVPR*, 2024.

[7] Lei, J. et al. "GART: Gaussian Articulated Template Models." *CVPR*, 2024.

[8] Hu, S. et al. "GauHuman: Articulated Gaussian Splatting from Monocular Human Videos." *CVPR*, 2024.

[9] Li, J. et al. "Animatable Gaussians: Learning Pose-dependent Gaussian Maps for High-fidelity Human Avatar Modeling." *CVPR*, 2024.

[10] Moon, G. et al. "ExAvatar: Expressive Whole-Body 3D Gaussian Avatar." *ECCV*, 2024.

[11] Liu, S. et al. "HumanGaussian: Text-Driven 3D Human Generation with Gaussian Splatting." *CVPR*, 2024.

[12] Rombach, R. et al. "High-Resolution Image Synthesis with Latent Diffusion Models." *CVPR*, 2022. (Stable Diffusion, SDS의 기반)

[13] Cao, A. & Johnson, J. "HexPlane: A Fast Representation for Dynamic Scenes." *CVPR*, 2023.

[14] Tancik, M. et al. "Fourier Features Let Networks Learn High Frequency Functions in Low Dimensional Domains." *NeurIPS*, 2020. (위치 인코딩 이론적 분석)

용어집

3DGS 3D Gaussian Splatting. 3D 가우시안 프리미티브로 장면을 표현하는 실시간 렌더링 방법.

Alpha Compositing 알파 합성. 반투명 레이어를 front-to-back 순서로 합성하여 최종 색상을 계산하는 기법.

Anisotropic 비등방성. 방향에 따라 성질이 다른 것. 3DGS에서 가우시안이 세 축으로 다른 크기를 가질 수 있음.

Blend Shapes 블렌드 셰이프. 기본 메시에 더해지는 꼭짓점 변위 벡터의 가중합.

Canonical Space 캐노니컬 공간. 기본 자세(T-pose 등)에서의 좌표 공간. 모든 프레임의 공통 기준.

Covariance Matrix 공분산 행렬. 3D 가우시안의 모양과 방향을 정의하는 3×3 대칭 양정치 행렬.

Differentiable Rendering 미분 가능 렌더링. 렌더링 과정이 미분 가능하여, 이미지 손실로부터 장면 파라미터로 역전파 가능.

Forward Kinematics 순방향 운동학. 관절 각도로부터 말단(end-effector) 위치를 계산하는 과정.

Forward Skinning 순방향 스키닝. 캐노니컬 공간 점을 관찰 공간으로 변환. ↔ 역방향 스키닝.

GART Gaussian Articulated Representation Templates. SMPL 스키닝으로 구동되는 3DGS 인체 아바타.

HexPlane 4D 시공간을 6개 2D 평면으로 분해하는 표현 방식.

Latent Bones 잠재 뼈. GART에서 비강체 변형을 위해 추가하는 가상 관절/뼈.

LBS Linear Blend Skinning. 선형 혼합 스키닝. 뼈 변환의 가중합으로 꼭짓점을 변형.

MLP Multi-Layer Perceptron. 다층 퍼셉트론. 완전연결 신경망.

NeRF Neural Radiance Fields. MLP로 장면을 암묵적 체적 함수로 표현하는 방법.

Observation Space 관찰 공간. 특정 자세/시점에서의 좌표 공간. ↔ 캐노니컬 공간.

Opacity 불투명도. 0(완전 투명)~1(완전 불투명).

Quaternion 쿼터니언. 4개 성분으로 3D 회전을 표현하는 수 체계. 짐벌 락(gimbal lock) 없음.

Rasterization 래스터화. 기하학적 프리미티브를 픽셀로 변환하는 과정.

SDS Score Distillation Sampling. 사전 학습된 확산 모델의 점수를 증류하여 3D 생성을 가이드하는 기법.

SH Spherical Harmonics. 구면 조화. 구면 위의 함수를 표현하는 직교 기저 함수 집합.

SMPL Skinned Multi-Person Linear Model. 체형+자세 파라미터로 인체 메시를 생성하는 모델.

SMPL-X SMPL + 손(MANO) + 얼굴(FLAME)을 통합한 표현력 있는 인체 모델.

Splatting 스플래팅. 3D 프리미티브를 2D 이미지 평면에 투영하여 렌더링하는 기법. ↔ 레이 마칭.

Transmittance 투과율. 레이가 특정 지점까지 아무 물체에도 부딪히지 않고 도달할 확률.

Volume Rendering 볼륨 렌더링. 레이를 따라 색상과 밀도를 적분하여 픽셀 색상을 계산하는 방법.