GART-Pitch Master Plan

신경 렌더링 기반 투구 생체역학 분석 종합 로드맵

3DGS · 4DGS · GART · GauHuman
현재 상태, 근본적 한계, 그리고 현실적 경로

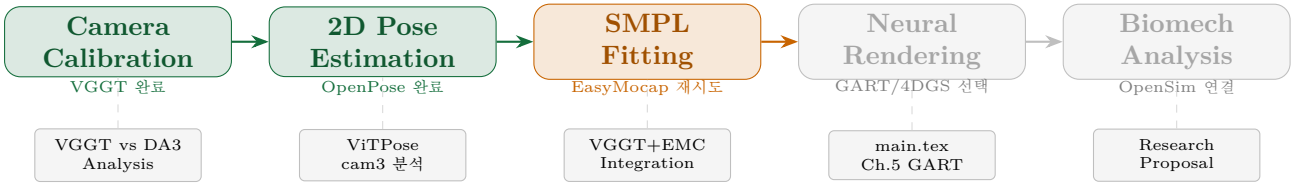

2026년 4월 12일

17개 교재/분석 문서를 종합하여, 신경 렌더링 기반 투구 생체역학 분석의
현재 위치와 앞으로의 경로를 제시합니다.

Contents

1 현재 상태: 어디까지 왔는가 **2**
1.1 프로젝트 문서 체계 . . . 2
1.2 파이프라인 진행 상황 . . . 3

2 신경 렌더링 방법 비교: 우리 데이터에 적합한가? **4**
2.1 후보 방법들 . . . 4
2.2 왜 GART가 1순위인가 . . . 5
2.2.1 GART의 한계 (본 프로젝트 맥락) . . . 5
2.3 Fallback: 3DGS-Avatar (JMBO) . . . 5
2.4 극단적 Fallback: SkelSplat (SMPL-free) . . . 5

3 GART 다시점 확장: 구체 설계 **7**
3.1 GART의 카메라-공간 아키텍처 . . . 7
3.2 필요한 코드 변경: 단 1줄 . . . 7
3.3 데이터 준비: VGGT 결과 → ZJU-MoCap 포맷 . . . 8
3.4 학습 전략 (Config 변경) . . . 9
3.5 다시점이 주는 구체적 이점 . . . 9

4 근본적 한계와 신경 렌더링 **11**
4.1 한계 1: 240Hz에서 7프레임 (가속 단계) . . . 11
4.1.1 대응 전략 . . . 11
4.2 한계 2: 7대 카메라 (기존 연구는 20+대) . . . 12
4.3 한계 3: SMPL 초기값 품질 . . . 12

5 VGGT 이후: 구체적 실행 계획 **13**
5.1 Phase A: SMPL 피팅 확보 (즉시 실행) . . . 13
5.2 Phase B: 신경 렌더링 (SMPL 확보 후) . . . 14
5.3 Phase C: 생체역학 분석 (GART 성공 후) . . . 14

6 의사결정 트리 **15**

7 최종 요약: 무엇을 해야 하는가 **16**

Chapter 1

현재 상태: 어디까지 왔는가

1.1 프로젝트 문서 체계

Table 1.1: 프로젝트 문서 17개 — 작성 순서 및 역할

문서	역할	상태
이론 교재 (*Part 1–3*)		
main.tex	NeRF → 3DGS → SMPL → 4DGS → GART 이론	완료
part2_motion_analysis	마커리스 모션캡처 + 보행 분석 이론	완료
part3_pitching	7시점 투구 분석 이론 + 실험 설계	완료
기반 기술 (*Part 0*)		
part0_camera_math	카메라 수학 완전 가이드 (한국어)	완료
part0_colmap_theory	COLMAP 이론 + DA3 좌표계 분석	완료
part0_progress_report	개발 진행 보고서	완료
데이터 분석 + 피팅 (*Part 4–5*)		
part4_data_analysis	다시점 데이터 분석	완료
part4_openpose_smpl_fitting	OpenPose→SMPL 수학적 정식화	완료
part5_constraints_setup	제약조건 분석	완료
part5_dev_setup	개발 환경 A-to-Z	완료
part5_research_proposal	GART-Pitch 연구 제안서	완료
실전 가이드		
fitting_guide	SMPL 피팅 오답노트	완료
methodology_survey	SMPL-free 방법론 서베이	완료
vitpose_cam3_analysis	ViTPose person tracking 실패 분석	완료
금일 작성 (*VGGT 시리즈*)		
vggt_vs_da3_analysis	DA3 vs VGGT 캘리브레이션 비교	**신규**
vggt_easymocap_integration	VGGT→EasyMocap 통합 가이드	**신규**
pipeline_issues_solutions	12개 문제점 종합 해결 방안	**신규**

1.2 파이프라인 진행 상황

Table 1.2: 파이프라인 단계별 현황

단계	작업	상태	비고
0	Camera Calibration	완료	VGGT: K, R, t (7대, 원본 해상도)
1	Segmentation (SAM3)	완료	cam7 마스크 방향 수정 완료
2	2D Pose (OpenPose)	완료	25 keypoints × 7 cams × 100 frames
3	SMPL Fitting	재시도	VGGT K로 EasyMocap 재실행 예정
4	Neural Rendering	대기	GART / 4DGS / GauHuman 선택
5	Biomech Analysis	대기	SMPL→OpenSim 연결

Chapter 2

신경 렌더링 방법 비교: 우리 데이터에 적합한가?

2.1 후보 방법들

Table 2.1: 신경 렌더링 방법 비교 — 투구 분석 적합성

방법	입력	SMPL 필요	다시점	고속 동작	학습 시간	적합도
3DGS	정적 이미지	No	Yes	불가	5–30분	부적합
4DGS	다시점 비디오	No	Yes	불확실	1–2시간	보통
GART	단안/다시점	**Yes**	Yes	미검증	0.5–2.5분	**높음**
GauHuman	단안/다시점	Yes	Yes	미검증	1–2분	높음
ExAvatar	단안/다시점	SMPL-X	Yes	미검증	1.5–5시간	높음
3DGS-Avatar	다시점	HMR급	Yes	미검증	2–4시간	**높음**
SkelSplat	다시점	**No**	Yes	미검증	1–3시간	보통

2.2 왜 GART가 1순위인가

Key Idea

GART가 이 프로젝트에 가장 적합한 이유:

1. **SMPL 기반 관절 표현**: 출력이 곧 $(\boldsymbol{\theta}, \boldsymbol{\beta})$ → 생체역학 분석에 직접 연결
2. **캐노니컬 공간**: 한 번 학습하면 임의 자세로 구동 가능
3. **포즈 정제**: photometric loss로 SMPL 초기 추정 오차를 보정
4. **빠른 학습**: 0.5–2.5분/장면 (다른 방법 대비 10–100배 빠름)
5. **잠재 뼈(latent bones)**: 루즈한 야구복의 비강체 변형 표현 가능

2.2.1 GART의 한계 (본 프로젝트 맥락)

Warning

1. **SMPL 초기값 의존**: 프레임별 $(\boldsymbol{\theta}, \boldsymbol{\beta})$가 없으면 시작 불가
2. **단안 기반 설계**: 원논문은 단안 비디오 기준. 7시점 다시점 확장 필요
3. **고속 동작 미검증**: 기존 검증은 걷기/춤 (최대 ~300 deg/s)
4. **포즈 정제 한계**: 초기 SMPL이 너무 틀리면 local minima에 빠질 수 있음

2.3 Fallback: 3DGS-Avatar (JMBO)

SMPL 초기값 품질이 나쁠 경우를 대비한 차선책:

3DGS-Avatar with Joint Multi-view Body Optimization

- CVPR 2024, 다시점 전용 설계
- HMR 수준의 **약한 초기값**으로도 작동 (EasyMocap 실패해도 가능)
- 3DGS 학습과 SMPL-X 최적화를 **동시 수행** (joint optimization)
- Photometric + keypoint + silhouette loss 통합
- 단점: 학습 시간 2–4시간, GART보다 복잡

2.4 극단적 Fallback: SkelSplat (SMPL-free)

SMPL 피팅이 근본적으로 실패할 경우:

SkelSplat (WACV 2026)

- SMPL 없이 스켈레톤을 가우시안으로 직접 모델링
- 3D GT 불필요, 2D 키포인트만으로 학습 가능
- 단점: 생체역학 연결이 어려움 (SMPL 파라미터 출력 없음)
- 단점: 논문 수준의 구현만 존재, 투구 동작 미검증

Chapter 3

GART 다시점 확장: 구체 설계

GART 소스코드(`github.com/JiahuiLei/GART`)를 분석한 결과, 다시점 확장은 **예상보다 훨씬 간단하다.** GART는 이미 ZJU-MoCap (21대 카메라) 포맷을 지원하며, 단안 모드는 `training_view=[4]`로 카메라 1대만 선택한 특수 케이스일 뿐이다.

3.1 GART의 카메라-공간 아키텍처

핵심 설계: 모든 것이 카메라 좌표계에서 동작

GART는 월드 좌표계를 사용하지 않는다. 대신:

1. 데이터 로딩 시: SMPL의 global orientation $\mathbf{R}_h$, translation $\mathbf{t}_h$를 카메라 좌표로 변환

$$[\mathbf{R}_h^{(cam)}, \mathbf{t}_h^{(cam)}] = [\mathbf{R}_{cw}, \mathbf{t}_{cw}] \circ [\mathbf{R}_h^{(world)}, \mathbf{t}_h^{(world)}] \tag{3.1}$$

2. 렌더링 시: 카메라가 항상 원점 — viewmatrix $= \mathbf{I}_{4\times4}$
3. 결과: 각 (프레임, 카메라) 쌍이 독립적인 학습 샘플

이 설계 덕분에, 카메라 수를 늘려도 렌더러를 수정할 필요가 없다.

3.2 필요한 코드 변경: 단 1줄

최소 변경

`lib_data/zju_mocap.py`, line 81:

```
# 기존 (단안):
training_view=[4],

# 변경 (7대 카메라):
training_view=[0, 1, 2, 3, 4, 5, 6],
```

이것만으로 다시점 학습이 작동한다.

나머지 코드가 이미 다시점을 지원하는 이유:

Table 3.1: GART 코드의 다시점 호환성 분석

모듈	현재 동작	7대 카메라 시 변화
`zju_mocap.py` 데이터 로더	`ims` 를 `training_view` 로 필터	7배 많은 샘플 ($100 \times 7 = 700$)
`zju_mocap.py` SMPL 변환 (190–211 줄)	각 이미지의 `cam_ind` 로 T_{cw} 적용	카메라별 올바른 T_{cw} 자동 적용
`data_provider.py` `__getitem__`	샘플별 K, pose, trans 반환	카메라별 다른 K, 다른 카메라-공간 pose
`solver.py` `_fit_step`	배치 내 각 샘플 독립 렌더링, loss 평균	7개 뷰의 loss가 자동 평균됨
`gauspl_renderer.py` 렌더러	카메라 원점 고정, K만 사용	K가 카메라별로 다르지만 이미 per-sample
`model.py` 캐노니컬 가우시안	뷰와 무관 (공유)	**변경 없음** — 7개 뷰가 같은 캐노니컬 구속

3.3 데이터 준비: VGGT 결과 → ZJU-MoCap 포맷

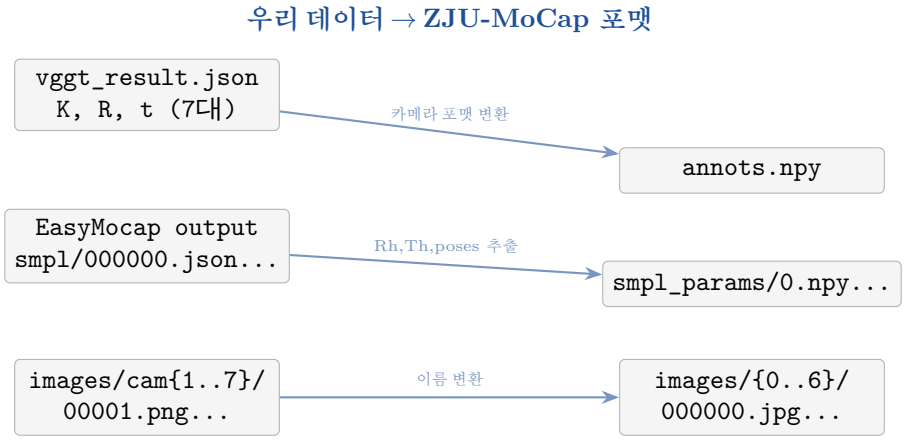

Figure 3.1: 데이터 변환 파이프라인

`annots.npy` 구조:

```
annots = {
  "cams": {
```

```
    "K": [K_cam0, K_cam1, ..., K_cam6],    # 7 x (3,3)
    "R": [R_cam0, R_cam1, ..., R_cam6],    # 7 x (3,3), world-to-cam
    "T": [T_cam0, T_cam1, ..., T_cam6],    # 7 x (3,1), 밀리미터 단위!
    "D": [zeros(5), zeros(5), ..., zeros(5)]  # 왜곡 = 0
  },
  "ims": [
    {"ims": ["0/000000.jpg", "1/000000.jpg", ..., "6/000000.jpg"]},
    {"ims": ["0/000001.jpg", "1/000001.jpg", ..., "6/000001.jpg"]},
    ...  # 100 frames
  ]
}
```

Warning

주의: ZJU-MoCap의 T는 **밀리미터** 단위. VGGT의 t는 정규화된 좌표 (∼0–1.3). 변환 시 스케일 팩터를 곱해야 한다 (또는 코드에서 `T / 1000.0` 하는 부분을 조정).

3.4 학습 전략 (Config 변경)

Table 3.2: 단안 vs 다시점 Config 비교

파라미터	단안 (기본)	7시점 (제안)	이유
TOTAL_steps	3,000	**7,000**	7배 데이터 → ∼2.3배 스텝
N_POSES_PER_STEP	1	**4**	GPU 메모리 허용 범위 내 병렬 렌더링
IMAGE_ZOOM_RATIO	0.5	**0.25**	1920×1080 → 480×270 (메모리 절약)
MAX_SPH_ORDER	1	**2**	다시점 → 더 많은 SH 계수 학습 가능
DENSIFY_END	2,400	**5,000**	더 긴 학습에 맞춰 연장
POSE_OPT_START	1,500	**3,500**	캐노니컬 가우시안 안정화 후 포즈 정제 시작

3.5 다시점이 주는 구체적 이점

1. **스키닝 가중치 학습 강화**: 정면에서 보이지 않는 등 쪽 가우시안도 후면 카메라에서 supervision을 받음
2. **SH 색상 학습 향상**: 7개 시점 방향 → SH order 2 (9개 계수)를 안정적으로 학습
3. **자기 가림(self-occlusion) 해소**: 한 카메라에서 가려진 관절이 다른 카메라에서 보임
4. **포즈 정제 정확도**: 7개 뷰의 photometric loss → SMPL 포즈 자유도 88개를 더 강하게 구속
5. **정량적**: 1프레임 × 7카메라 × 480×270 = ∼**907K pixel supervision** (단안의 7배)

다시점 확장 요약

- **코드 변경**: `training_view` 1줄 + config 조정
- **데이터 변환**: VGGT + EasyMocap 출력 → annots.npy + smpl_params/ 변환 스크립트 작성
- **학습 시간**: A100에서 ∼30–60분 (7,000 스텝)
- **근본적 아키텍처 수정**: 불필요. GART는 이미 다시점을 지원.

Chapter 4

근본적 한계와 신경 렌더링

4.1 한계 1: 240Hz에서 7프레임 (가속 단계)

Table 4.1: 투구 단계별 프레임 수 및 신경 렌더링 영향

투구 단계	시간	프레임 (@240Hz)	신경 렌더링 영향
Wind-up	∼1.0s	∼240	충분. GART 학습에 이상적
Stride	∼0.5s	∼120	충분
Arm cocking	∼0.15s	∼36	가능하나 temporal 정규화 필요
Acceleration	**∼0.03s**	**∼7**	**부족. 모션 블러 + 학습 데이터 부족**
Deceleration	∼0.35s	∼84	충분
Follow-through	∼0.5s	∼120	충분

Current Limitation

가속 단계에서 신경 렌더링의 한계:

- 7프레임으로는 GART의 per-frame 가우시안 외형을 학습하기 어려움
- 모션 블러로 photometric loss의 gradient가 부정확
- 프레임 간 29°/frame 변화 → 이전 프레임의 가우시안 위치가 다음 프레임의 초기값으로 부적합

4.1.1 대응 전략

1. **다시점 보상**: 7대 카메라 × 7프레임 = 49장의 학습 이미지. 단안 GART(1장/프레임)보다 7배 많은 supervision.
2. **Phase-aware training**: 투구 단계별로 GART 학습 전략 분리.
   - Wind-up∼Stride: 표준 학습 (캐노니컬 가우시안 초기화에 사용)

- Acceleration: 높은 학습률 + temporal smoothing 완화 + 캐노니컬 가우시안 고정 (포즈만 최적화)

3. **목표 재정의**: 가속 단계의 외형 재구성은 포기. 대신 포즈 정제에 집중. 7대 카메라의 silhouette + keypoint loss만으로 가속 구간의 $\boldsymbol{\theta}$를 정제.

4.2 한계 2: 7대 카메라 (기존 연구는 20+대)

Table 4.2: 카메라 수 vs 신경 렌더링 품질

방법	사용 카메라	비고
ZJU-MoCap (원본 GART 벤치마크)	21대	동기화, 고정 위치
Human3.6M	4대	낮은 해상도
우리 데이터	**7대**	240Hz, 고해상도

Key Idea

7대는 21대보다 적지만, 각 카메라가 1920×1080 @ 240Hz라는 점이 보상 요인.

- 1프레임에서 7 viewpoint × 2M pixel = **14M pixel supervision**
- ZJU-MoCap: 21 viewpoint × 1024×1024 = 22M pixel (비슷한 규모)
- 시간 축으로 누적하면 7대 × 100프레임 = 700장 ≫ 충분

4.3 한계 3: SMPL 초기값 품질

이것이 **현재 가장 중요한 병목**이다.

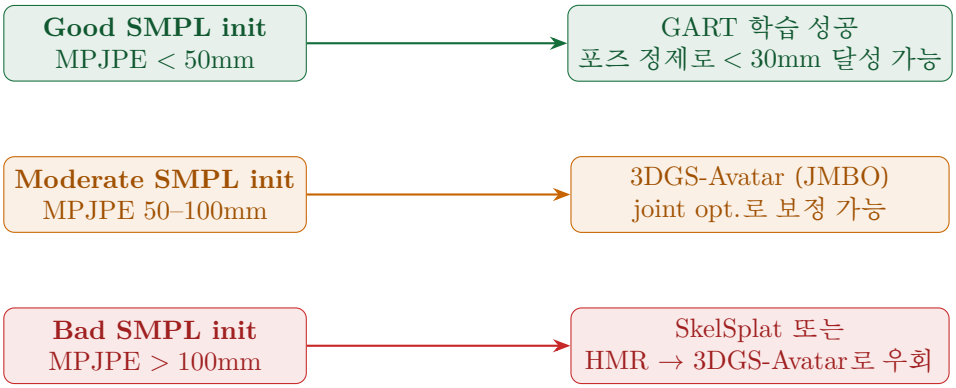

Figure 4.1: SMPL 초기값 품질에 따른 신경 렌더링 전략

Chapter 5

VGGT 이후: 구체적 실행 계획

5.1 Phase A: SMPL 피팅 확보 (즉시 실행)

A1. VGGT → EasyMocap (1일)

1. `vggt_to_easymocap.py` 실행: VGGT JSON → intri.yml + extri.yml
2. EasyMocap `mv1p.py` 실행: 삼각측량 + SMPL 피팅
3. 검증: reprojection error, MPJPE, SMPL 오버레이 시각화

성공 기준: MPJPE < 50mm, reprojection error < 10px

A2. Fallback: smplx 직접 피팅 (2–3일)

EasyMocap 실패 시:

1. VGGT K, R, t로 OpenPose 2D → DLT 삼각측량 (직접 구현)
2. smplx + PyTorch로 3D keypoint → SMPL 직접 피팅
3. Full SMPL_NEUTRAL.pkl (21MB) + $\lambda_\theta = 0.0001$
4. 4-stage coarse-to-fine: global → shape → pose → joint

A3. Extreme Fallback: HMR 초기값 (1일)

삼각측량 자체가 실패 시:

1. 각 카메라에서 독립적으로 HMR2.0 / SMPLest-X 실행
2. 7대 카메라의 SMPL 추정값 평균으로 초기화
3. 3DGS-Avatar (JMBO)로 joint optimization

5.2 Phase B: 신경 렌더링 (SMPL 확보 후)

B1. GART 학습 (1순위, 1–2일)

1. 데이터 준비: 7 cameras × 100 frames, SMPL per frame, K/R/t
2. GART 포맷으로 변환 (ZJU-MoCap 스타일)
3. 캐노니컬 가우시안 학습 (wind-up 구간 중심)
4. 전체 시퀀스 포즈 정제 (photometric + silhouette loss)

코드: `github.com/JiahuiLei/GART`
입력: images, masks, SMPL params, cameras
출력: 정제된 $(\boldsymbol{\theta}, \boldsymbol{\beta})$ per frame + animatable avatar

B2. 다시점 확장 (GART 수정)

원본 GART는 단안 기반. 다시점으로 확장:

1. Rendering loss를 7대 카메라 모두에서 계산
2. 각 프레임에서 7개 뷰의 photometric loss 합산
3. 카메라별 K, R, t를 학습 시 고정 (calibration 신뢰)

수정 범위: GART의 `train.py`에서 데이터 로더 + loss 계산 부분

5.3 Phase C: 생체역학 분석 (GART 성공 후)

C1. SMPL → OpenSim 연결 (3–5일)

1. GART 출력 $(\boldsymbol{\theta}, \boldsymbol{\beta})$ → smplx FK → 메시 정점
2. SMPL2AddBiomechanics: 가상 마커 추출 → TRC
3. AddBiomechanics: TRC → 스케일링된 .osim + IK .mot
4. 관절 각도, angular velocity 추출

코드: `github.com/MarilynKeller/SMPL2AddBiomechanics`
출력: ISB 관절 각도, MER, 어깨 내회전 속도

C2. Vicon 검증 (1–2일)

서버에 Vicon 데이터 존재 (`pipeline/data/vicon/`).

1. RGB ↔ Vicon 시간 동기화 (LED 또는 이벤트 기반)
2. Vicon 마커 기반 관절 각도 추출 (GT)
3. GART-Pitch vs Vicon: Bland-Altman, ICC, RMSE 비교

Chapter 6

의사결정 트리

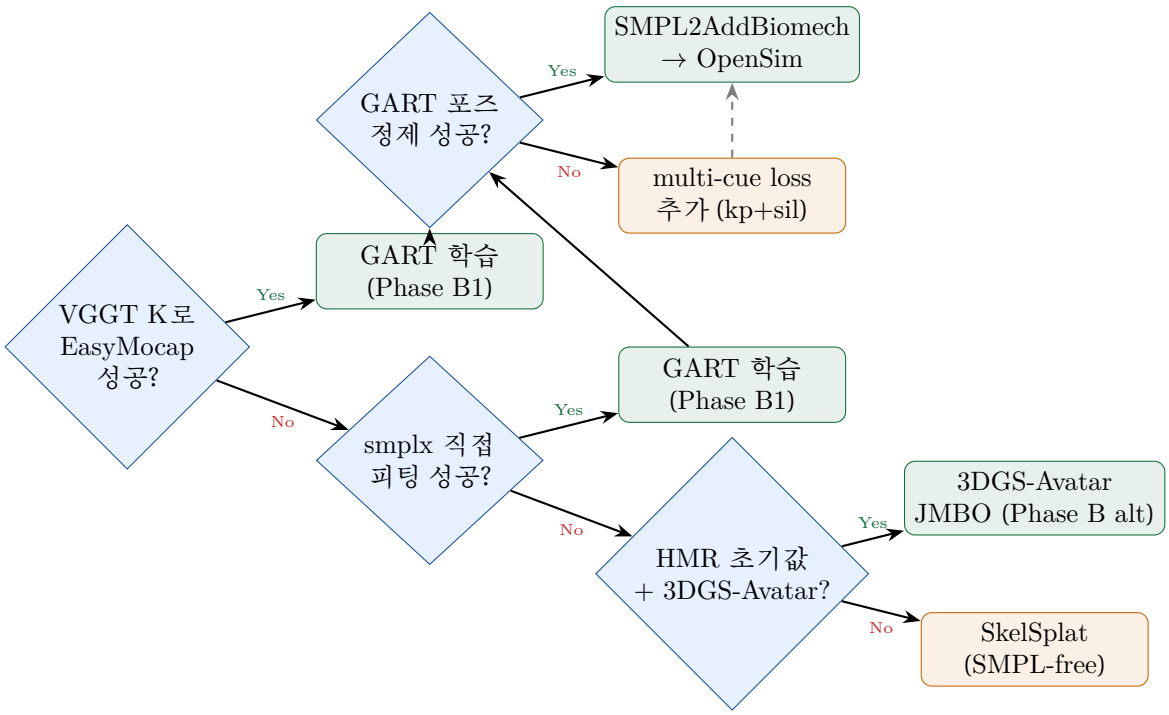

Figure 6.1: SMPL 품질에 따른 의사결정 트리

Chapter 7

최종 요약: 무엇을 해야 하는가

Summary

즉시 실행 (오늘–내일):

1. `vggt_to_easymocap.py` 서버 실행 → intri.yml, extri.yml 생성
2. EasyMocap `mv1p.py` 실행 → SMPL 피팅
3. Reprojection error + SMPL 오버레이 검증

SMPL 확보 후 (2–3일):

4. GART 데이터 포맷 변환 (7 cams → ZJU-MoCap 스타일)
5. GART 학습 (A100에서 ∼30분)
6. 다시점 rendering loss 확장 (코드 수정)
7. 포즈 정제 결과 검증 (MPJPE, 시각화)

신경 렌더링 성공 후 (3–5일):

8. SMPL2AddBiomechanics → TRC → OpenSim IK
9. 관절 각도 + angular velocity 추출
10. Vicon 데이터와 비교 검증

논문 작성 가능 시점: Phase C 완료 후, "다시점 RGB만으로 투구 생체역학 분석"이라는 제목의 논문 가능. 핵심 기여:

- VGGT 기반 mixed-orientation 카메라 캘리브레이션
- GART의 다시점 확장 (7 cameras, 240Hz)
- 고속 스포츠 동작에서의 신경 렌더링 기반 포즈 정제
- GART → SMPL2AddBiomechanics → OpenSim 통합 파이프라인